# Data Analytics 半期 Cheat Sheet •A 面：大题解题手册（80′）

范围：L2 SQL ·L3/L4 相似搜索·L5/L6 机器学习·L7 降维
10 MCQ(20′) + 4 大题 (80′) | **带校园卡!** (A 面 1/2)

## SQL（L2)•骨架与执行顺序

```
SELECT [DISTINCT] 列 |*| 聚合 FROM 表 [WHERE 行条件] [GROUP BY 列] [HAVING 组条件] [ORDER BY 列 ASC|DESC]
```

**执行顺序**: FROM(笛卡尔积/连接)→WHERE(筛行，**禁用聚合**)→GROUP BY→HAVING(筛组，**可用聚合**)→SELECT(算列/DISTINCT)→ORDER BY。

投影**不自动去重**，要唯一值必须写 DISTINCT; ORDER BY 默认 ASC, DESC 降序，并列 (tie) 按第二排序列破平。

## SQL •连接与「算行数」三步法

**三种连接写法**: `FROM A,B WHERE A.k=B.k` ≡ `FROM A JOIN B ON A.k=B.k` (内连接)；LEFT/RIGHT/FULL OUTER JOIN 保留未匹配行，对面补 NULL。

**行数题三步**: 笛卡尔积行数 $= |A| \times |B|$; 按 WHERE 逐行过滤; 投影 (**无 DISTINCT 重复行保留**，结果是 multiset)。

**【例】例 1**: $R.A = \{1,3\}, S.B = \{(2,3),(3,4),(3,5)\}$, `SELECT R.A FROM R,S WHERE R.A=S.B`: $2 \times 3 = 6$ 组合 → 留下 $(3,(3,4))$、$(3,(3,5))$ → 输出 **(3),(3) 两行。例 2**: $4 \times 3 = 12$ 组合 → 条件只剩 1 行。**例 3**: LEFT JOIN 行数 = 内连接 + 左表未匹配 $= 3+1 = 4$ 行。

**反连接** (在 A 不在 B): `A LEFT JOIN B ON A.k=B.k WHERE B.k IS NULL`。**OR 陷阱**: `SELECT DISTINCT R.A FROM R,S,T WHERE R.A=S.A OR R.A=T.A` 看似 $R \cap (S \cup T)$，实为三表笛卡尔积过滤——**只要 S 或 T 有空表，结果整体为空**；两个查询都加 DISTINCT 才谈等价。

## SQL •NULL 三值逻辑 (必考)

TRUE= 1, FALSE= 0, **UNKNOWN**= 0.5; 任何含 NULL 的比较 → UNKNOWN (**连 NULL=NULL 也是**)。

$C_1$ AND $C_2 = \min(C_1, C_2)$; $C_1$ OR $C_2 = \max(C_1, C_2)$; NOT $C_1 = 1 - C_1$; WHERE 只保留结果 = 1 的行

**【例】 经典陷阱**: `WHERE age<25 OR age>=25` 漏掉 age=NULL 的行 $(\max(0.5, 0.5) = 0.5 \neq 1) \rightarrow$ 补 `OR age IS NULL`。判空只能 **IS NULL / IS NOT NULL**，不能 =NULL。

**聚合与 NULL**: SUM/AVG/MIN/MAX 自动跳过 NULL; COUNT(∗) = 全部行, COUNT($col$) = 非 NULL 行, COUNT(DISTINCT $col$) = 不同值数; AVG = SUM/COUNT($col$); 列全 NULL 时 SUM→NULL、COUNT→ 0。

## SQL •嵌套、集合运算、约束

**嵌套**: IN(值/子查询); EXISTS(相关子查询，行是否存在); **全称量词**「所有产品都 ≥ 100」→`SELECT c FROM Comp c WHERE NOT EXISTS (SELECT * FROM Prod p WHERE p.c=c.c AND p.price<100)` (找反例取非)。$x >$ ANY$(\cdots)$ = 比最小值大; $x >$ ALL$(\cdots)$ = 比最大值大。

**集合运算**: UNION(去重)/UNION ALL(全保留、更快); INTERSECT、EXCEPT **默认集合语义去重**; bag 计数 $\lambda(X \text{ UNION ALL } Y) = \lambda_X + \lambda_Y$。

**改写**: $R \cap S$ →JOIN 全列相等 (+DISTINCT) 或 EXISTS; $R - S$ →NOT EXISTS 或反连接。

**主键**唯一 + 非空 (自动索引); **外键** `FOREIGN KEY(cid) REFERENCES Course(id)`: 插入悬空引用 → **拒绝**; 删父行三策略: **拒绝 / CASCADE 级联删 / SET NULL**。

**索引** (B-tree): 加速 WHERE/JOIN, **拖慢增删改**。LIKE: % 任意串、_ 单字符。DDL=CREATE/DROP/ALTER; DML=SELECT/INSERT/UPDATE/DELETE。

## SQL •聚合与 GROUP BY 手算 (三步语义)

五个聚合 SUM/COUNT/MIN/MAX/AVG; **除 COUNT(*) 外都作用于单列。**

GROUP BY 三步: WHERE 筛行 按分组列分组 组内算聚合，每组输出一行; HAVING 事后再筛组 (可含聚合)

**【例】课件手算例** Purchase(bagel $1 \times 20$、banana $0.5 \times 10$、banana $1 \times 10$、bagel $1.5 \times 20$): `SELECT product, SUM(price*quantity) AS TotalSales FROM Purchase WHERE date>'10/1/2005' GROUP BY product` → bagel $= 1 \times 20 + 1.5 \times 20 =$ **50**, banana $= 0.5 \times 10 + 1 \times 10 =$ **15**; 全表 SUM= **65**。**SUM(price*quantity)≠SUM(price)×SUM(quantity)** (逐行先乘再累加)。

## SQL •六大题型模板 (对号入座)

**哪些 Y 满足 X**: JOIN+WHERE+**DISTINCT** (防连接放大)。**最贵/最便宜**: MAX/MIN 或 ORDER BY · · · DESC 取首行;「价格 = 最高价」需子查询。 **每类统计**: GROUP BY+ 聚合，组筛用 HAVING。 **在 A 不在 B**: NOT EXISTS / 反连接 / EXCEPT。 **全称「所有...都」**: NOT EXISTS 找反例; **存在「至少一个」**: EXISTS/IN。 **自比较** (比同类平均贵等): 同表两别名 p1,p2 相关子查询。

## 相似搜索 (L3/L4)•度量换算

Jaccard $s = |A \cap B| / |A \cup B|$, $d = 1 - s$ | 余弦 $s = (A \cdot B)/(\|A\| \cdot \|B\|) = \cos\theta$, $d = \theta/\pi$ | 欧氏 $\|A - B\|_2$ | Hamming= 不同位数

例: 交 3 并 8 → $s = 3/8 = 0.375$, $d = 5/8$; $\cos\theta = 0.5 \rightarrow \theta = 60° \rightarrow d = 1/3$。

**编辑距离 DP** (字符串/DNA): 表 $(n+1) \times (m+1)$, 首行 $= i$、首列 $= j$:

$E_{ij} = \min(E_{i-1,j-1} + \delta,\ E_{i-1,j} + 1,\ E_{i,j-1} + 1)$, $\delta =$ (字符不同? 1 : 0), 答案 $E_{nm}$

**【例】迷你例**: "ac" 到 "abc" 的距离 = 1: $E_{11} = 0$(a=a), $E_{12} = 1$(插 b), $E_{23} = 1$(c=c); 每格三方向取 min。

度量公理: 非负、同一性、对称、三角不等式 (Jaccard 距离、编辑距离都满足)。

## MinHash+LSH 计算模板 (大题必考)

**MinHash**: $P[h_{\min}(A) = h_{\min}(B)] = s$ (Jaccard 本身)。签名长 $k$ 条，估计 $\hat{s}$ = 相同行数 $/k$。

**Banding**: 签名切 $b$ 个 band × 每 band $r$ 行 ($k = b \cdot r$); 整 band 全同 → 同桶 → **候选对。**

四步: band 全同 $= t^r$ 不全同 $= 1 - t^r$ $b$ 个 band 都不同 $= (1-t^r)^b$ $P(\text{cand}) = 1-(1-t^r)^b$;阈值(拐点)$t^* \approx (1/b)^{1/r}$

**【例】 课件例** (找 $s = 0.8$ 相似对, $b = 20$, $r = 5$, $k = 100$): $0.8^5 = 0.328 \rightarrow (1-0.328)^{20} \approx$ **0.00035** = 漏检率 FN; 不相似对 $s = 0.3$: $0.3^5 = 0.00243 \rightarrow 1-(1-0.00243)^{20} \approx$ **4.74%** = 误报率 FP。

| $(b, r)$ | FN($s$=0.8) | FP($s$=0.3) | 特点 |
|---|---|---|---|
| $(20, 5)$ | 0.035% | 4.74% | 抓得全、误报多 |
| $(10, 10)$ | ≈ 32% | ≈ 0.006% | 误报少、漏检狠 |

**调参**: $b$ ↑→FP↑FN↓; $r$ ↑ 反之; 拐点 $t^*$ 落在阈值 $s$ 处最平衡。**S 曲线**: 横轴 $t$、纵轴 $P(\text{cand})$; $s$ 右侧曲线到 1 之间 =FN 区，左侧曲线下方 =FP 区。

**规模账**: 10 万文档 × 100 签名 × 4B = **40MB**; 全对比较 $\binom{n}{2} = n(n-1)/2$, $10^9$ 网页 → **$5 \times 10^{17}$ 对** ($10^{11}$ 对/天也算不完) → 必须 LSH 只比同桶。

## LSH 家族与概率放大 (L4)

| 度量 | 哈希函数 | 碰撞概率 |
|---|---|---|
| Jaccard | MinHash 分 band | $P = s$; band 全同 = 候选 |
| 余弦 | 随机超平面 $h(x) = \text{sign}(v \cdot x)$ | $P$[分界] $= \theta/\pi$ (simhash) |
| 欧氏 | p-稳定桶 $\lfloor \frac{v \cdot p + x}{a} \rfloor$, $x \in [0, a)$ | $d \leq a$ 时 $P$[同桶] $\geq 1 - \frac{d}{a}$ |
| Hamming | 位采样 (80% 相似 → 每位同 $P = 0.8$) | band OR: $1 - (1 - 0.8^r)^b$ |

**放大**: 概率 $p$ 的族 → AND($k$ 次)= $p^k$; OR($k$ 次)= $1-(1-p)^k$; 级联 $(r, b) = 1-(1-p^r)^b$ (与 banding 同式)。**OR 抬召回、AND 压误报**，组合调出相似对 → 1、不相似对 → 0。

欧氏直觉: 投影到随机直线，点落在桶边界 $a$ 内的概率 $\leq d/a \rightarrow$ **越近越易同桶**; 多组 $(v, x)$ 投影拼签名。

## 机器学习 (L5)•混淆矩阵与指标 (必考计算)

| | 预测 + | 预测 − |
|---|---|---|
| **实际 +** | TP | FN(漏报) |
| **实际 −** | FP(误报) | TN |

Acc $= \frac{TP+TN}{\text{总}}$, $P = \frac{TP}{TP+FP}$, $R(\text{TPR}) = \frac{TP}{TP+FN}$, Spec $= \frac{TN}{TN+FP}$, $F_1 = \frac{2TP}{2TP+FP+FN} = \frac{2PR}{P+R}$

**【例】 课件例**: TP= 9, FP= 2, FN= 1, TN= 8 (总 20) → Acc= $17/20 =$ **0.85**, Pr= $9/11 \approx$ **0.81**, Rec= $9/10 =$ **0.9**, Spec= $8/10 =$ **0.8**, $F_1 \approx$ **0.857**。

**阈值**默认 0.5; 调高 (如 0.6): TP、FP 都减 → **Precision↑Recall↓**。**ROC**: $x = \text{FPR} = 1 - \text{Spec}$, $y = \text{TPR} = \text{Recall}$; AUROC= 曲线下面积 (0.5= 随机, 1= 完美)。**PR 曲线**: $x$ =Rec, $y$ =Pr, 面积 =AUPRC。**类别不平衡** (患病率 < 5%): 全预测阴性 Accuracy 也虚高 → 失真; 此时 **Accuracy<AUROC<AUPRC**, 看 AUPRC。

**IoU**= 预测框 ∩ 真值框 / 预测框 ∪ 真值框; IoU≥ 0.5 判检测正确; mIoU= 各类平均。**CV 任务**: 分类 (整图 → 标签)、定位/检测 (框 + 类)、语义分割 (每像素 → 类)。

## ML 算法要点 (选择 + 简答)

**Mitchell 学习定义 (T-E-P)**: 在任务 T 上，凭经验 E，性能度量 P 随经验改善。

**KNN**: 无训练 (懒惰); $k$ 近邻投票/平均; 对 $k$ 与特征尺度敏感。**LR**: $\sigma(z) = 1/(1+e^{-z})$, $\sigma(w \cdot x + b) \geq 0.5 \Leftrightarrow w \cdot x + b \geq 0$, 边界 = 超平面。

**决策树**: 熵 $H = -\sum p \log_2 p$ (纯 = 0, 二等分 = 1); **信息增益** $IG = H(D) - \sum_v \frac{|D_v|}{|D|} H(D_v)$, 贪心选 IG 最大属性分裂。**数字例**: $H(12{:}8) = -(0.6\log_2 0.6 + 0.4\log_2 0.4) = 0.442 + 0.529 =$ **0.971**; $H(9{:}1) \approx 0.47$; $H(20{:}0) = 0$; 分裂后两组全纯 → $IG =$ 0.971。

**SVM**: 点到边界 $\frac{|w \cdot x + w_0|}{\|w\|}$; **间隔** $= \frac{2}{\|w\|}$ 最大化; 只有**支持向量**决定边界; 软间隔 $\min \|w\|^2 + C\sum \xi_i$ ($C$ 大 → 不容错 → 易过拟合); **核技巧** $K(x, y) = \phi(x) \cdot \phi(y)$, RBF: $K = e^{-\gamma\|x-y\|^2}$。

**CNN 尺寸公式**: $n_{out} = \lfloor (n_{in} + 2p - k)/s \rfloor + 1$ ($p$ 补边、$k$ 核、$s$ 步长)。例 $n = 5, k = 3, p = 1, s = 2 \rightarrow \lfloor 4/2 \rfloor + 1 =$ **3**。每个核对**全部输入通道求和** +bias; 输出 3×3×2。池化 (max/avg) **无参数**, $2 \times 2$、$s = 2 \rightarrow$ 减半。

**参数账**: 全连接 $224 \times 224 \times 3 \rightarrow 4096 \approx 150529 \times 4096 \approx$ **6 亿参数**; CNN **靠权值共享 + 稀疏连接**砍参数。AlexNet@ImageNet: **100 万图 / 1000 类 / 2×GPU / 约 1 周 / 6000 万参数。**

## ML 训练与过拟合

**初始化**: 全 0 不行 (神经元对称、梯度相同永远一样); Xavier $\sigma^2 = 1/n$; He(ReLU) $\sigma^2 = 2/n$。

**学习率**: 大 → 震荡/发散, 小 → 太慢; Momentum 累积惯性; Adam= 自适应逐参数学习率。mini-batch= 速度与噪声折中。**BN**= 批内标准化再 $\gamma, \beta$ 变换 → 分布稳、可用大 lr、加速收敛。

**CNN 反传**: 权值共享 → 同一核梯度 = 各位置梯度**累加**; max 池化梯度只回传给最大值位置。

**过拟合**: train 误差 ↓、val 误差 ↑; 对策 = 加数据/L2(weight decay)/L1(稀疏)/dropout/早停/减复杂度。**欠拟合**: 两者都高 → 加特征加容量。

## 聚类 (L6)•k-means (必考手算)

目标 min $SSE = \sum_i \sum_{x \in C_i} \|x - c_i\|^2$; Lloyd: 选 $k$ 初始质心 分配: 每点 → 最近质心 更新 $c_i = \text{mean}(C_i)$ 重复 至不变

**【例】 课件例** (一维 $0, 1, 5, 6$; $k = 2$; 初始 $c = (0, 6)$): 分配 $\{0, 1\}, \{5, 6\} \rightarrow$ 更新 $c =$ (**0.5, 5.5**) → 再分配无人换簇 → 收敛; $SSE = 4 \times 0.5^2 =$ **1**。

NP-hard→ 启发式; **初始化敏感** → 多跑取 SSE 最小; **k-means++**: 选下一质心概率 $\propto \mathbf{D(x)}^2$ ($D$ = 到最近已选质心距离)。**选 k**: 肘部法 (SSE-$k$ 曲线拐点)。**局限**: 球形/等大小簇、对离群点敏感; centroid= 均值 (人造点), k-medoids/clustroid= 真实代表点 (到簇内点距离和最小) → 更稳健。

## 层次聚类•BFR •CURE

**Agglomerative**:每点一簇 → 反复合并最近两簇 →**dendrogram**(叶 = $n$ 点, **高度 = 合并时簇间距离**, 横切一刀 = $k$ 簇)。**链接**: 单链 = 最近点对距离 (**链化效应** → 长条); 全链 = 最远点对 (紧凑球形); 平均/质心折中。**停止**: 给定 $k$ / 距离 > 阈值 $t$ / 剩单点。

**BFR**(磁盘大数据): 假设簇 = 轴对齐正态 (各维独立 → 对角协方差)。**DS**(近质心 → 并入后**丢弃**)/**CS**(彼此近未归队 → 内存聚类)/**RS**(孤立 → 原样保留)。流程: 读一批 → 近的进 DS→ 其余 + 旧 RS 内存聚 →CS/RS→ 合并 CS→ 循环; 最后 CS/RS 并入最近簇。

$2d+1$ 统计量: $N$、SUM($d$ 维)、SUMSQ($d$ 维); mean = SUM$/N$; Var = SUMSQ$/N$ − (SUM$/N$)$^2$; 合并簇 = 三项逐项相加

马氏距离 $d_M = \sqrt{\sum_i ((x_i - m_i)/\sigma_i)^2}$; $d_M < \sqrt{d} \rightarrow 1\sigma$ 内 (68%); $d_M < 2\sqrt{d} \rightarrow 2\sigma$ 内 (95%), 阈值常取 $2\sqrt{d}$

**【例】课件例**: $m = (2, 3)$, $\sigma = (1, 2)$, $x = (4, 5) \rightarrow y = ((4-2)/1, (5-3)/2) = (2, 1) \rightarrow d_M = \sqrt{4+1} = \sqrt{5} \approx$ **2.24**; $\sqrt{2} \approx 1.41$ 拒 ($1\sigma$), $2\sqrt{2} \approx 2.83$ 收 ($2\sigma$)。

**CURE**(任意形状): 抽样 → 层次聚类 → 每簇多代表点向质心**收缩** $\alpha = 0.2$ → 用代表点分配全量。**维度灾难**: $d$ 维保持体积 0.001 需边长 $0.001^{1/d}$ (10 维 → 0.5); 距离集中 → 聚类失效。

## 降维 (L7)•SVD 与 PCA (压轴必考)

$A_{m \times n} = U\Sigma V^T$: $U$ 列 = $AA^T$ 特征向量, $V$ 列 = $A^TA$ 特征向量, $\sigma_i = \sqrt{\lambda_i} \geq 0$ 降序; 秩 = 非零 $\sigma$ 数; 几何 = 旋转 $V^T$ → 拉伸 $\Sigma$ → 旋转 $U$

**必默写推导**: $A = U\Sigma V^T \Rightarrow A^TA = V\Sigma^TU^TU\Sigma V^T = \mathbf{V^2V^T}$ (用 $U^TU = I$、$\Sigma^T = \Sigma$); 同理 $AA^T = U\Sigma^2U^T$; $A^TAV = V\Sigma^2$。

**PCA 五步**: $X$ 中心化 (每列减均值) 协方差 $C = X^TX/(n-1)$ 特征分解 $C$ $\lambda$ 降序取前 $k$ 个特征向量拼 $W$ 投影 $\mathbf{Y = XW}$。等价: PCA 方向 = 中心化 $X$ 的**右奇异向量** $V$; **最大方差方向 = 最小重构误差方向。**

## 降维•手算模板 (照抄步骤)

$2 \times 2$ 特征值: $\lambda = \left(\text{tr} \pm \sqrt{\text{tr}^2 - 4\det}\right)/2$; $M = \left(\begin{smallmatrix} 1 & 2 \\ 2 & 3 \end{smallmatrix}\right)$: tr = 4, det $= -1 \rightarrow \lambda = (4 \pm \sqrt{20})/2 \approx 4.236 / -0.236$

**【例】 幂迭代** (找主特征对): $x \leftarrow Mx/\|Mx\|$。$x_0 = (1, 1)$: $Mx = (3, 5)$, $\|Mx\| = \sqrt{34} \approx 5.83 \rightarrow x_1 = (0.51, 0.86)$; 再 $Mx_1 = (2.23, 3.60)$, $\|\cdot\| = \sqrt{17.93} \rightarrow x_2 \approx$ (**0.53, 0.85**) 收敛; $\lambda = x^TMx \approx$ **4.25**。

**Deflation 缩并**: $M^* = M - \lambda xx^T$ (主方向清零) → 例 $M^* \approx \left(\begin{smallmatrix} -0.19 & 0.09 \\ 0.09 & -0.07 \end{smallmatrix}\right)$ → 再迭代得 $\lambda_2 \approx -0.24$ (理论 $2 - \sqrt{5} \approx -0.236$)。

**验证** $U\Sigma$ 坐标: $u_1\sigma_1 = (0.13 \times 12.4,\ 0.68 \times 12.4) = (1.61, 8.43)$。

## 低秩近似•能量•CUR

秩 $k$ 近似 $A_k = \sum_{i \leq k} \sigma_i u_i v_i^T$ (其余 $\sigma$ 置 0); **Eckart–Young**: $A_k$ =Frobenius 范数下最优 rank-$k$; 误差 $\|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \cdots + \sigma_r^2}$

Frobenius: $\|A\|_F = \sqrt{\sum\sum a_{ij}^2} = \sqrt{\sum \sigma_i^2}$。**能量 (方差解释) 比** $= \sigma_k^2 / \sum \sigma_i^2$; 例: 153.76+90.25+1.69= 245.7 → 留前 2: **244/245.7 ≈ 99.3%**,rank-2 误差 $= \sqrt{1.69} =$ **1.3**。存储 $k(m+n+1)$ vs $mn$。**去噪** = 小 $\sigma$ 视作噪声置零; **推荐** = 低秩补全缺失项。

**CUR**: 按概率 (∝ 列/行范数 $^2$, leverage 分数) 抽 $c$ 列 $r$ 行, 各乘 $1/\sqrt{c \cdot p_i}$ 缩放保无偏; $U \approx C^+AR^+$ (伪逆)。**CUR vs SVD**: 真实行列 → **可解释、保稀疏**; SVD 向量稠密、正交、误差最优。

# Data Analytics 半期 Cheat Sheet •B 面：选择题概念辨析 + 全公式速查

MCQ $10\times2'$ | 先排除含 always/never/only 的绝对化选项

**带校园卡!** (B 面 2/2)

## B1 •L2 SQL 概念辨析（选择题大户）

| | |
|---|---|
| WHERE / HAVING | 筛行、分组前、**禁聚合** / 筛组、分组后、可聚合 |
| UNION / UNION ALL | 去重（集合语义）/ 保留重复 (bag)、省去重更快 |
| IN / EXISTS / ANY · ALL | 成员资格 / 行存在 (相关子查询) / >ANY 比最小大、>ALL 比最大大 |
| INNER / LEFT JOIN | 只留匹配行 / 左表全保留、未匹配右侧 NULL |
| COUNT 三种 | COUNT(*) 所有行 / COUNT(col) 非 NULL / COUNT(DISTINCT col) 不同值数 |
| DDL / DML | CREATE · DROP · ALTER / SELECT · INSERT · UPDATE · DELETE |
| 主键 / 外键 | 唯一 + 非空 + 自动索引 / 引用约束：拒绝、CASCADE、SET NULL |
| LIKE 通配 | % 任意长度串 / _ 恰好一个字符 |

**NULL 口诀**：比较得 0.5; AND= min、OR= max、NOT= $1-x$; WHERE 只留 1; 判空只能 IS (NOT) NULL; 聚合跳 NULL 但 COUNT(*) 不跳。**集合 vs multiset**：默认去重，ALL 切计数语义，**DISTINCT**：消连接放大; IN 嵌套与三表连接**都加 DISTINCT 才等价。**索引：查询快、写入慢。

## B2 •L3/L4 相似搜索辨析

| 度量 | 适用 | sim→dist |
|---|---|---|
| Jaccard | 集合/关键词/文档 | $d=1-s$ |
| 余弦 | 向量方向 (文本 TF) | $d=\theta/\pi$ 或 $1-\cos\theta$ |
| 编辑距离 | 字符串/DNA/拼写 | 本身是距离 |
| 欧氏 | 空间点 | — |
| Hamming | 二进制指纹 | 不同位数 |

**LSH 家族配对**：Jaccard→MinHash banding($P=s$); 余弦 → 随机超平面 $\text{sign}(v\cdot x)$, $P=\theta/\pi$; 欧氏 →p-稳定桶 $\lfloor(v\cdot p+x)/a\rfloor$, $P\geq 1-d/a$; Hamming→ 位采样。**敏感族** = 碰撞概率等于相似度。$b$ ↑: 候选多 (FP↑FN↓); $r$ ↑: 更严 (FP↓FN↑); S 曲线 $P=1-(1-t^r)^b$, 拐点 $t^*=(1/b)^{1/r}$; 右面积 =FN、左面积 =FP。**放大**: AND= $p^k$, OR= $1-(1-p)^k$。**为什么 LSH**: $\binom{n}{2}$ 全对不可行 ($10^9$ 页 → $5\times10^{17}$ 对) → 只比同桶。**MinHash 原理**：随机排列下最小元素相同 $\Leftrightarrow$ 该元素落在交集，$P$ =Jaccard。

## B3 •L5 机器学习辨析

**三类学习**：监督 (有标签 → 分类/回归)、无监督 (无标签 → 聚类/降维)、强化 (奖励序贯决策)。回归 = 连续值, 分类 = 离散标签。**T-E-P**(Mitchell): 任务-经验-性能。

**P vs R 取舍**: FP 代价高 (误杀正常邮件)→ 重 Precision; FN 代价高 (疾病漏诊)→ 重 Recall; $F_1$ = 调和平均。阈值 ↑→ $P$ ↑ $R$ ↓。AUROC: 0.5 随机、1 完美; 稀有类看 AUPRC; **Accuracy<AUROC<AUPRC。**

**KNN**: 非参数/懒惰学习。**决策树**: 熵 0= 纯; 选 IG 最大; 贪心。**SVM**: 间隔 $2/\|w\|$; 只有支持向量决定边界; $C$ 大 → 不容错易过拟合; 核 = 隐式高维内积 (RBF)。

**CNN 组件**: 卷积 = 局部感受野 + 权值共享 (砍参数); 池化 = 降采样 + 平移不变 (max/avg 无参数); 激活 = 非线性 (ReLU); BN= 稳定分布、可大 lr; dropout= 防过拟合。**全 0 初始化** → 对称破不了。Xavier $\sigma^2=1/n$; He $\sigma^2=2/n$(ReLU)。lr 大震荡、小龟速; Momentum 冲平台; Adam 自适应。

**过拟合**: train↓val↑ → 数据/L1L2/dropout/早停/减复杂度; **欠拟合**: 都高 → 加容量。**CV 任务输出**: 分类 = 标签、检测 = 框 + 类 (IoU≥ 0.5 对)、分割 = 逐像素。**AlexNet**: 1M 图/1000 类/2GPU/1 周/60M 参数; 全连接 $224^2\cdot3\to4096\approx6$ 亿参数 → 必须卷积。

## B4 •L6 聚类辨析

**centroid(均值,人造点) vs clustroid(真实点,到簇内点距离和最小)**→ 后者抗离群。**单链** = 最近点对 → **链化**适合长条; **全链** = 最远点对 → 紧凑球形; 平均/质心折中。dendrogram: 高度 = 合并距离、横切得 $k$。停止: 定 $k$/阈值 $t$/剩单点。

**k-means 失效场景**: 非球形、簇大小悬殊、离群点多、初始化差 →k-means++($P\propto D^2$)/多跑。**BFR 三集合**: DS 已归队丢弃、CS 抱团未归队、RS 散兵原样留。**2d+1**: $N$+SUM+SUMSQ (轴对齐 → 对角协方差 → 不用存 $d\times d$, 否则爆内存)。

**马氏 vs 欧氏**: 各维先除以 $\sigma$ (把椭圆簇掰圆) 再量; 阈值 $\sqrt{d}(1\sigma,68\%)/2\sqrt{d}(2\sigma,95\%)$。**CURE**: 多代表点 + 向质心收缩 0.2→ 任意形状。**维度灾难**: 体积缩水 (边长 $0.001^{1/d}$)、距离集中、稀疏 → 先降维再聚类。

## B5 •L7 降维辨析

**SVD vs 特征分解**: SVD 任意 $m\times n$ 都有 ($U,V$ 正交、$\Sigma\geq0$ 降序); 特征分解仅方阵可对角化时; 对称阵特征向量正交。$\mathbf{A^TA}\to\mathbf{V}$、$\mathbf{AA^T}\to\mathbf{U}$、$\lambda=\sigma^2$。**秩** = 非零奇异值数。**PCA**= 协方差 $X^TX/(n-1)$ 的特征向量 = 中心化 $X$ 的右奇异向量; 最大方差 $\Leftrightarrow$ 最小重构误差。

**Eckart–Young**: 截断 =Frobenius 最优 rank-$k$; 误差 = $\sqrt{\sigma_{k+1}^2+\cdots}$ (**被扔掉的**)。能量比 = $\sigma_k^2/\sum\sigma_i^2$, 选 $k$ 使 ≈ 99%。置零小 $\sigma$ = 低秩近似 (维度不变, 等价)。**CUR**: 真实行列、可解释、保稀疏、抽样 $p\propto$ 范数 $^2$、缩放 $1/\sqrt{c\cdot p}$; SVD: 稠密正交、误差最优。幂迭代 $x\leftarrow Mx/\|Mx\|$ (每步必须归一化), $\lambda=x^TMx$; deflation $M-\lambda xx^T$ 逐层剥离。降维收益: 存储/速度/可视化/去噪; 代价: 信息损失、可解释性降。特征提取 (组合新特征,PCA) vs 特征选择 (挑原特征子集)。

## B6 •英中术语对照（考卷是英文!）

**SQL**: relation 表·tuple 行·attribute 列·multiset(bag) 多重集·Cartesian product 笛卡尔积·projection 投影 (选列) ·selection 选择 (筛行) · inner/outer join 内/外连接·anti-join 反连接·correlated subquery 相关子查询·three-valued logic 三值逻辑·aggregate 聚合·constraint 约束·primary/foreign key 主/外键·referential integrity 引用完整性·CASCADE 级联·index 索引

**相似搜索**: similarity search 相似性搜索·Jaccard/cosine/edit distance 杰卡德/余弦/编辑距离·shingle 碎片·signature matrix 签名矩阵·banding 分 band ·band/row/bucket band/行/桶·candidate pair 候选对·S-curve S 曲线·threshold 阈值·false positive/negative 误报/漏检·LSH 局部敏感哈希·random hyperplane 随机超平面·simhash 相似哈希·p-stable p-稳定分布·amplification 放大·near-duplicate 近重复

**ML**: supervised/unsupervised/reinforcement 监督/无监督/强化·classification/regression 分类/回归·confusion matrix 混淆矩阵·precision 精确率·recall(sensitivity) 召回率·specificity 特异度·prevalence 正类占比·IoU 交并比·detection/segmentation 检测/分割·convolution 卷积·kernel/filter 卷积核·stride/padding 步长/补边·pooling 池化·activation 激活·backprop 反向传播·learning rate 学习率·mini-batch 小批量·batch normalization 批归一化·dropout 随机失活·over/underfitting 过/欠拟合·regularization 正则化·support vector 支持向量·margin 间隔·soft margin 软间隔·kernel trick 核技巧·entropy 熵·information gain 信息增益

**聚类**: dendrogram 树状图·agglomerative 凝聚式·single/complete-link 单链/全链·chaining effect 链化效应·centroid 质心 (均值) · clustroid/medoid 簇代表点·elbow method 肘部法·curse of dimensionality 维度灾难·Mahalanobis distance 马氏距离·discard/compress/retained set 丢弃/压缩/保留集·axis-aligned Gaussian 轴对齐高斯·leverage score 杠杆分数

**降维**: dimensionality reduction 降维·feature extraction/selection 特征提取/选择·SVD 奇异值分解·singular value 奇异值·eigenvector/eigenvalue 特征向量/特征值·covariance 协方差·PCA 主成分分析·centering 中心化·power iteration 幂迭代·deflation 缩并·rank-k approximation 秩 k 近似·Eckart–Young 最优低秩定理·Frobenius norm F 范数·variance explained 方差解释比·pseudo-inverse 伪逆·sparse/dense 稀疏/稠密

## B7 •判断速测（先自测，错的记纠正）

| 说法 | ✓/× | 纠正 |
|---|---|---|
| 编辑距离越大越相似 | × | 越小越相似 |
| MinHash 碰撞概率 = 1−Jaccard | × | =Jaccard $s$ 本身 |
| AUROC= 0.5 是完美模型 | × | 0.5= 瞎猜, 1 才完美 |
| SVM 的 $C$ 越大正则越强 | × | $C$ 大 → 不容错 → 正则弱 |
| SVM 边界由所有样本决定 | × | 只由支持向量决定 |
| 池化层有可学习参数 | × | max/avg 池化无参数 |
| 全 0 初始化的网络能正常学习 | × | 对称破不了 → 随机初始化 |
| k-means 必收敛到全局最优 | × | 局部最优 → 多跑/k-means++ |
| k-means++ 均匀随机选质心 | × | $P\propto D(x)^2$ 越远越易中 |
| 单链聚合易产生链化效应 | ✓ | 全链才给紧凑簇 |
| BFR 要存 $d\times d$ 协方差 | × | 轴对齐 → $2d+1$(N,SUM,SUMSQ) |
| 马氏距离 = 欧氏距离 | × | 各维先除 $\sigma$ (椭圆掰圆) |
| SVD 的奇异值可以为负 | × | $\sigma=\sqrt{\lambda}\geq0$, 降序排 |
| PCA 不中心化也没关系 | × | 必须先每列减均值 |
| rank-$k$ 误差 $=\sqrt{\sigma_1^2+\cdots+\sigma_k^2}$ | × | $=\sqrt{\sigma_{k+1}^2+\cdots}$ 被扔掉的 |
| CUR 比 SVD 可解释 | ✓ | 真实行列; SVD 向量稠密 |
| UNION ALL 比 UNION 慢 | × | 不去重反而更快 |

## B8 •数字速记（课件原值，选择题对号）

LSH: $0.8^5=0.328$, $(1-0.328)^{20}\approx0.00035$(FN); $0.3^5=0.00243$ → 4.74%(FP); $k=100=b\cdot r$; 10 万文档签名 =40MB; $10^9$ 页 → $5\times10^{17}$ 对; $10^{11}$ 对/天

指标: TP9/FP2/FN1/TN8 → Acc .85、Pr .81、Rec .9、Spec .8、$F_1$ .857; IoU≥ 0.5; AUROC .5= 随机; $H(9{:}1)\approx0.47$, $H(12{:}8)\approx0.97$

CNN: $\lfloor(5+2-3)/2\rfloor+1=3$; 全连接 $224^2\cdot3\to4096\approx6$ 亿参; AlexNet: 1M 图/1000 类/2GPU/1 周/60M 参; Xavier $1/n$、He $2/n$

聚类: $0,1,5,6\to c=(0.5,5.5)$、$SSE=1$; $d_M=\sqrt{5}\approx2.24$ vs $\sqrt{2}\approx1.41$、$2\sqrt{2}\approx2.83$; CURE $\alpha=0.2$; $0.001^{1/10}=0.5$

SQL: bagel= 50、banana= 15、全表 SUM(price*quantity)= 65; $R\{1,3\}\times S$ 三行 → 输出 (3),(3); LEFT JOIN $3+1=4$ 行

降维: $\lambda=(4\pm\sqrt{20})/2\approx4.236/-0.236$; $\sqrt{34}\approx5.83\to(0.51,0.86)\to(0.53,0.85)$, $\lambda\approx4.25$; $M^*\approx\left(\begin{smallmatrix}-0.19 & 0.09\\ 0.09 & -0.07\end{smallmatrix}\right)$; 能量 $153.76+90.25+1.69=245.7$, $244/245.7\approx99.3\%$

## B9 •MCQ 高频易错坑集

precision≠accuracy; centroid(均值点)≠clustroid(真实点); WHERE 不能有聚合、HAVING 可以; NULL=NULL→UNKNOWN, 只能 IS NULL; COUNT(*) 不跳 NULL, COUNT(col) 跳, SUM/AVG 跳; UNION 去重、UNION ALL 不去; INTERSECT/EXCEPT 默认去重; IN 嵌套与 JOIN 改写**都加 DISTINCT 才等价**; 笛卡尔积里有空表 → 结果整体为空。

$b$ ↑→FP↑FN↓, $r$ ↑ 反之; S 曲线拐点 $=(1/b)^{1/r}$; $s$ 右侧面积 =FN、左侧 =FP; MinHash 碰撞概率 =Jaccard 本身 (不是 1−Jaccard); 超平面 $P=\theta/\pi$; p-稳定 $P\geq1-d/a$ 只在 $d\leq a$ 时成立。

阈值 ↑→ $P$ ↑ $R$ ↓ (不会双升) ; 稀有类 Accuracy 虚高: Accuracy<AUROC<AUPRC; FPR= 1−Spec; $F_1$ 是调和平均 (≤ 算术平均); 全 0 初始化 → 对称破不了; He= $2/n$(ReLU)、Xavier= $1/n$; SVM 边界只由支持向量决定; $C$ 大 → 不容错 → 易过拟合; lr 大 → 震荡发散。

单链 → 链化/长条簇 (不是紧凑); 全链 → 紧凑; dendrogram 高度 = 合并时距离; BFR 存 **2d+1** 个数 (不是 $d^2$); Var= SUMSQ/$N$ − (SUM/$N$)$^2$; 马氏先除 $\sigma$ 再算欧氏; k-means++ 概率 $\propto D(x)^2$; 肘部法看 SSE-$k$ 拐点。

$A^TA$ 的特征向量是 **V** (不是 $U$); $\sigma=\sqrt{\lambda}\geq0$; 秩 = 非零 $\sigma$ 数; rank-$k$ 误差 = **被扔掉的** $\sigma^2$ 和开根; Eckart–Young 对 Frobenius 范数最优; 能量比 $=\sigma_k^2/\sum\sigma_i^2$; PCA 必须先中心化; CUR 抽样 $p\propto$ 范数 $^2$、缩放 $1/\sqrt{c\cdot p}$; deflation 减 $\lambda xx^T$; 幂迭代每步必须归一化。

## B10 •读图要点（看图题经典失分点）

**S 曲线**: 横轴 = 相似度 $t$, 纵轴 = $P$( 成候选 ); **拐点 ≈ 阈值**; $s$ 右侧与 1 之间 =FN 区、左侧下方 =FP 区; $r$ 越大曲线越陡 (越像阶跃)。**ROC**: 横 =FPR(= 1−Spec)、纵 =TPR(=Recall); 对角线 = 随机 (0.5); 越贴**左上角**越好。**PR 曲线**: 横 =Recall 纵 =Precision, 稀有类比模型看 AUPRC。**树状图**: 纵轴 = 合并时簇间距离; 横切一刀 → 连通块数 = $k$; 长竖线 = 簇稳定。**肘部图**: 横 = $k$ 纵 =SSE, 取拐弯点。**能量图**: 横 = $k$ 纵 = 累计 $\sigma^2$ 占比, 取达 ∼ 99% 的最小 $k$。

## B11 •全公式速查（考前 10 分钟扫这里）

$s=\frac{|A\cap B|}{|A\cup B|}$, $d=1-s$ | $\cos\theta=\frac{A\cdot B}{\|A\|\cdot\|B\|}$, $d=\theta/\pi$ | $E_{ij}=\min(E_{i-1,j-1}+\delta,\ E_{i-1,j}+1,\ E_{i,j-1}+1)$ | MinHash $P=s$ | $P(\text{cand})=1-(1-t^r)^b$, $t^*=(1/b)^{1/r}$ | 超平面 $P=\theta/\pi$ | p-稳定 $P\geq1-d/a$ | AND $p^k$、OR $1-(1-p)^k$ | $\binom{n}{2}=n(n-1)/2$

NULL: AND= min、OR= max、NOT= $1-x$ | $\lambda$(UNION ALL) = $\lambda_X+\lambda_Y$ | WHERE 只留 TRUE | $H=-\sum p\log_2 p$ | $IG=H(D)-\sum\frac{|D_v|}{|D|}H(D_v)$ | $\sigma(z)=\frac{1}{1+e^{-z}}$ | 间隔 $\frac{2}{\|w\|}$、点距 $\frac{|w\cdot x+w_0|}{\|w\|}$ | RBF $K=e^{-\gamma\|x-y\|^2}$ | $n_{out}=\lfloor\frac{n_{in}+2p-k}{s}\rfloor+1$ | 全连接参数 $=(in+1)\times out$ | Xavier $\sigma^2=1/n$、He $2/n$

Acc= $\frac{TP+TN}{N}$、$P=\frac{TP}{TP+FP}$、$R=\frac{TP}{TP+FN}$、Spec= $\frac{TN}{TN+FP}$、$F_1=\frac{2TP}{2TP+FP+FN}$、FPR= 1−Spec | IoU= $\frac{|\cap|}{|\cup|}$ | $SSE=\sum\sum\|x-c_i\|^2$, $c_i=\text{mean}(C_i)$、k-means++ $P\propto D(x)^2$ | Var= $\frac{\text{SUMSQ}}{N}-(\frac{\text{SUM}}{N})^2$、$2d+1$ | $d_M=\sqrt{\sum((x_i-m_i)/\sigma_i)^2}$、阈值 $\sqrt{d}$, $2\sqrt{d}$ | CURE $\alpha=0.2$ | 体积边长 $V^{1/d}$

$A=U\Sigma V^T$ | $A^TA=V\Sigma^2V^T$、$AA^T=U\Sigma^2U^T$、$\sigma=\sqrt{\lambda}$ | $\lambda=\frac{\text{tr}\pm\sqrt{\text{tr}^2-4\det}}{2}$ | $C=\frac{X^TX}{n-1}$, $Y=XW$ | $A_k=\sum_{i\leq k}\sigma_iu_iv_i^T$、误差 $=\sqrt{\sum_{i>k}\sigma_i^2}$ | 能量 $=\sigma_k^2/\sum\sigma_i^2$ | $\|A\|_F=\sqrt{\sum\sigma_i^2}$ | CUR: $p\propto\|\text{col}\|^2$、$\times\frac{1}{\sqrt{c\cdot p}}$、$U=C^+AR^+$ | 幂迭代 $x\leftarrow\frac{Mx}{\|Mx\|}$、$\lambda=x^TMx$ | deflation $M^*=M-\lambda xx^T$

## B12 •考场策略（4 大题 ×20′）

**时间**: MCQ ≤15′ (1.5′/题), 大题各 ∼20′; 先扫全卷挑最熟的开始。**大题模板**: 写定义/公式 代题目数字 逐步算 (保留中间结果) 回应问题 (几行/哪类/比率含义); 算不完也把公式步骤写上拿过程分。

**高频大题预测**: SQL 写查询 + 算结果行数; LSH 给 $s,b,r$ 算 FP/FN 或选参数; 混淆矩阵算五指标 + 阈值影响; k-means 一轮迭代 (分配 + 更新 +SSE) 或马氏距离判归簇; $2\times2$ 矩阵 PCA/幂迭代/deflation 或秩-$k$ 近似能量比。

**MCQ 排坑**: 绝对化词先排除; 不等号方向 (Acc<AUROC<AUPRC、P∝FP、R∝FN) ; 术语张冠李戴 (precision≠accuracy、centroid≠clustroid、单链 ≠ 全链) ; 数字题快速估算量级。**再提醒：带校园卡!**